

UAS DEEP LEARNING

Pengembangan Sistem Deteksi Anomali pada Data Sensor IoT Industri Menggunakan Arsitektur Hybrid CNN–LSTM

Disusun oleh:

- M. Febri Ardiansyah G1A022049
- Baim Mudrik Aziz G1A022071
- Mezi G1A022077

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2025

ABSTRAK: Deteksi Anomali IoT Industri

Penelitian ini mengembangkan sistem deteksi anomali pada data sensor IoT industri menggunakan arsitektur hybrid CNN–LSTM. Data sensor industri (time series) rentan anomali akibat gangguan operasional atau kegagalan mesin.



Dataset

MetroPT-3 Air Compressor Dataset (UCI ML Repository) merekam parameter operasional kompresor udara.

Tahapan

Pemuatan data, pelabelan anomali (tekanan/suhu), normalisasi, segmentasi sliding window, pembagian data.

Model & Evaluasi

CNN–LSTM dilatih dengan class weighting dan early stopping. Dievaluasi dengan Accuracy, Precision, Recall, F1-Score, ROC-AUC, dan dibandingkan dengan Random Forest & SVM.

Model terbaik dikonversi ke TensorFlow Lite (TFLite) untuk implementasi perangkat edge IoT.

Latar Belakang: Tantangan Anomali IoT Industri

Perkembangan IoT mentransformasi otomasi industri (IIoT) dengan sensor yang memantau operasional mesin real-time. Data sensor deret waktu mencerminkan dinamika variabel penting seperti tekanan, suhu, getaran, dan konsumsi energi.

Anomali Data

Data sensor sering terpengaruh noise, kesalahan pengukuran, dan anomali akibat keausan komponen atau kegagalan sistem.

Deteksi Dini

Krusial untuk keandalan dan efektivitas operasional, memungkinkan tindakan preventif sebelum kegagalan total.



Keterbatasan Metode Tradisional

Metode deteksi anomali tradisional, seperti berbasis aturan dan statistik, memiliki keterbatasan signifikan dalam menangani data sensor IoT yang kompleks.

Data Multivariat & Non-linear

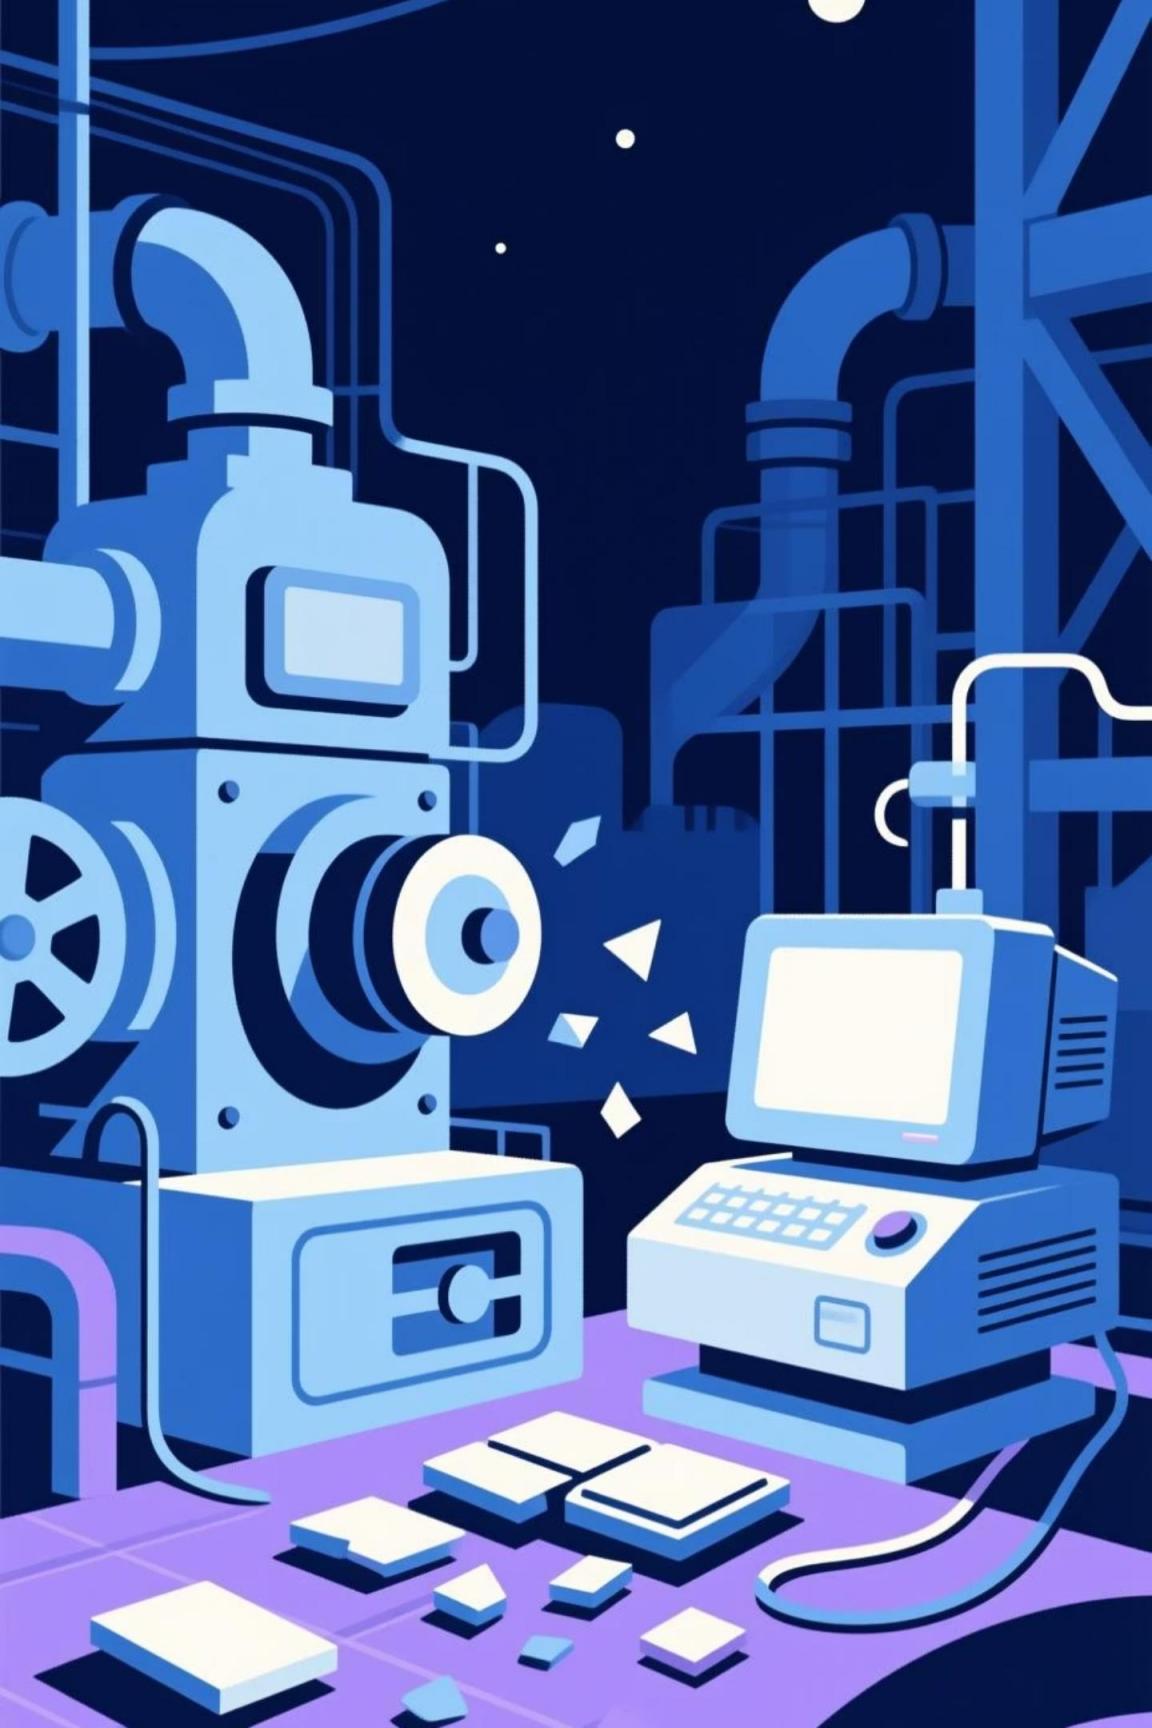
Metode tradisional kesulitan menangani data sensor IoT yang multivariat, non-linear, dan memiliki ritme temporal kompleks.

Asumsi Distribusi Data

Metode statistik sering memerlukan asumsi distribusi data yang tidak realistik dalam praktik industri.

Dependensi Jarak Jauh

Kurang fleksibel dalam menangkap hubungan fitur jarak jauh dalam data deret waktu sensor, menyebabkan kegagalan di skenario nyata.



Pendekatan Deep Learning

Deep learning semakin banyak digunakan karena kemampuannya mempelajari pola kompleks secara otomatis dari data mentah, tanpa rekayasa fitur manual.



CNN

Mengekstrak fitur lokal dan pola struktural dalam sekuens data.



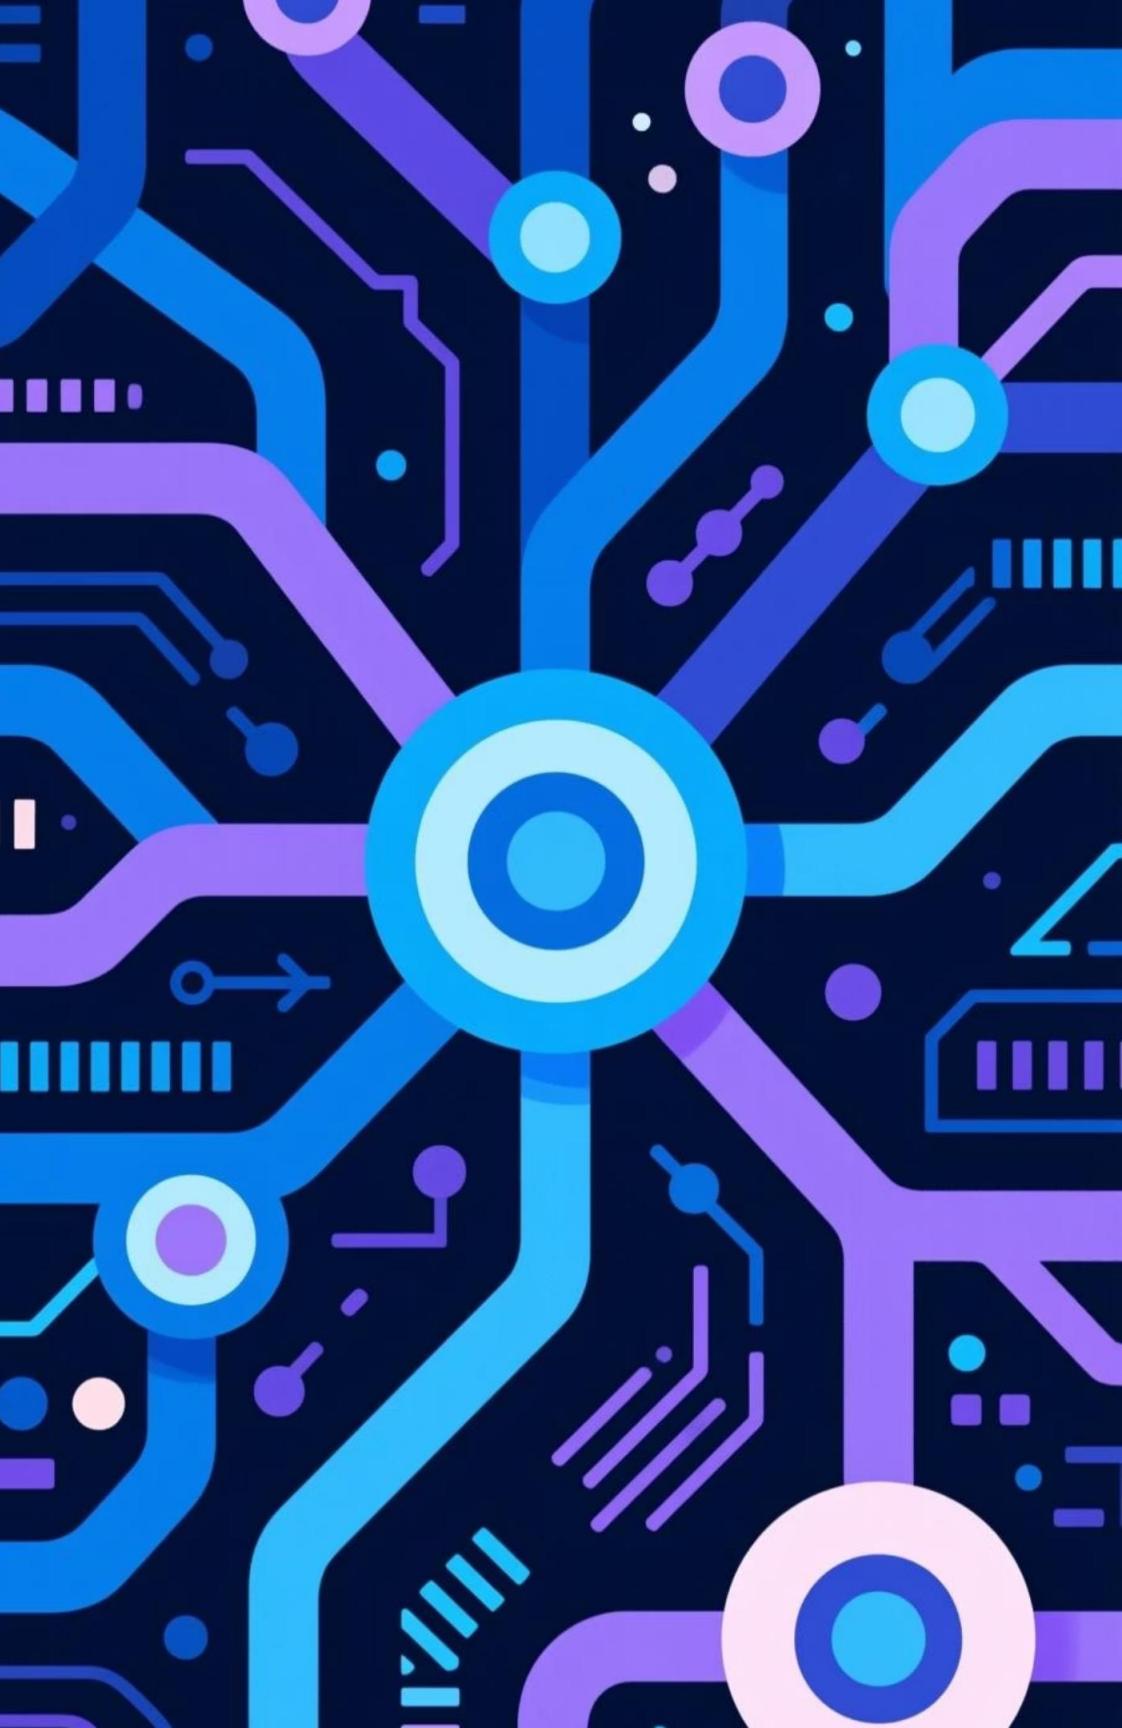
LSTM

Menangkap ketergantungan jangka panjang dalam deret waktu, relevan untuk data sensor.



CNN-LSTM

Menggabungkan kekuatan CNN dan LSTM untuk deteksi anomali yang efektif.



Metodologi Penelitian

01

Identifikasi Masalah & Dataset

Deteksi anomali pada data sensor IoT multivariat dan time series. Menggunakan MetroPT-3 Air Compressor Dataset (100.000 baris pertama).

03

Normalisasi Data

Min-Max Scaling ke rentang [0,1] untuk stabilitas pelatihan model CNN-LSTM.

05

Perancangan & Implementasi Model

Model CNN-LSTM dengan lapisan Conv1D, MaxPooling, LSTM, Dropout, dan Dense sigmoid.

02

Pra-pemrosesan & Eksplorasi Data

Konversi waktu ke timestamp, pelabelan anomali (tekanan TP2 < 5 bar atau suhu oli > 80°C), visualisasi distribusi kelas.

04

Segmentasi & Pembagian Dataset

Sliding window (ukuran 50 timestep). Pembagian: 70% latih, 15% validasi, 15% uji (menjaga urutan temporal).

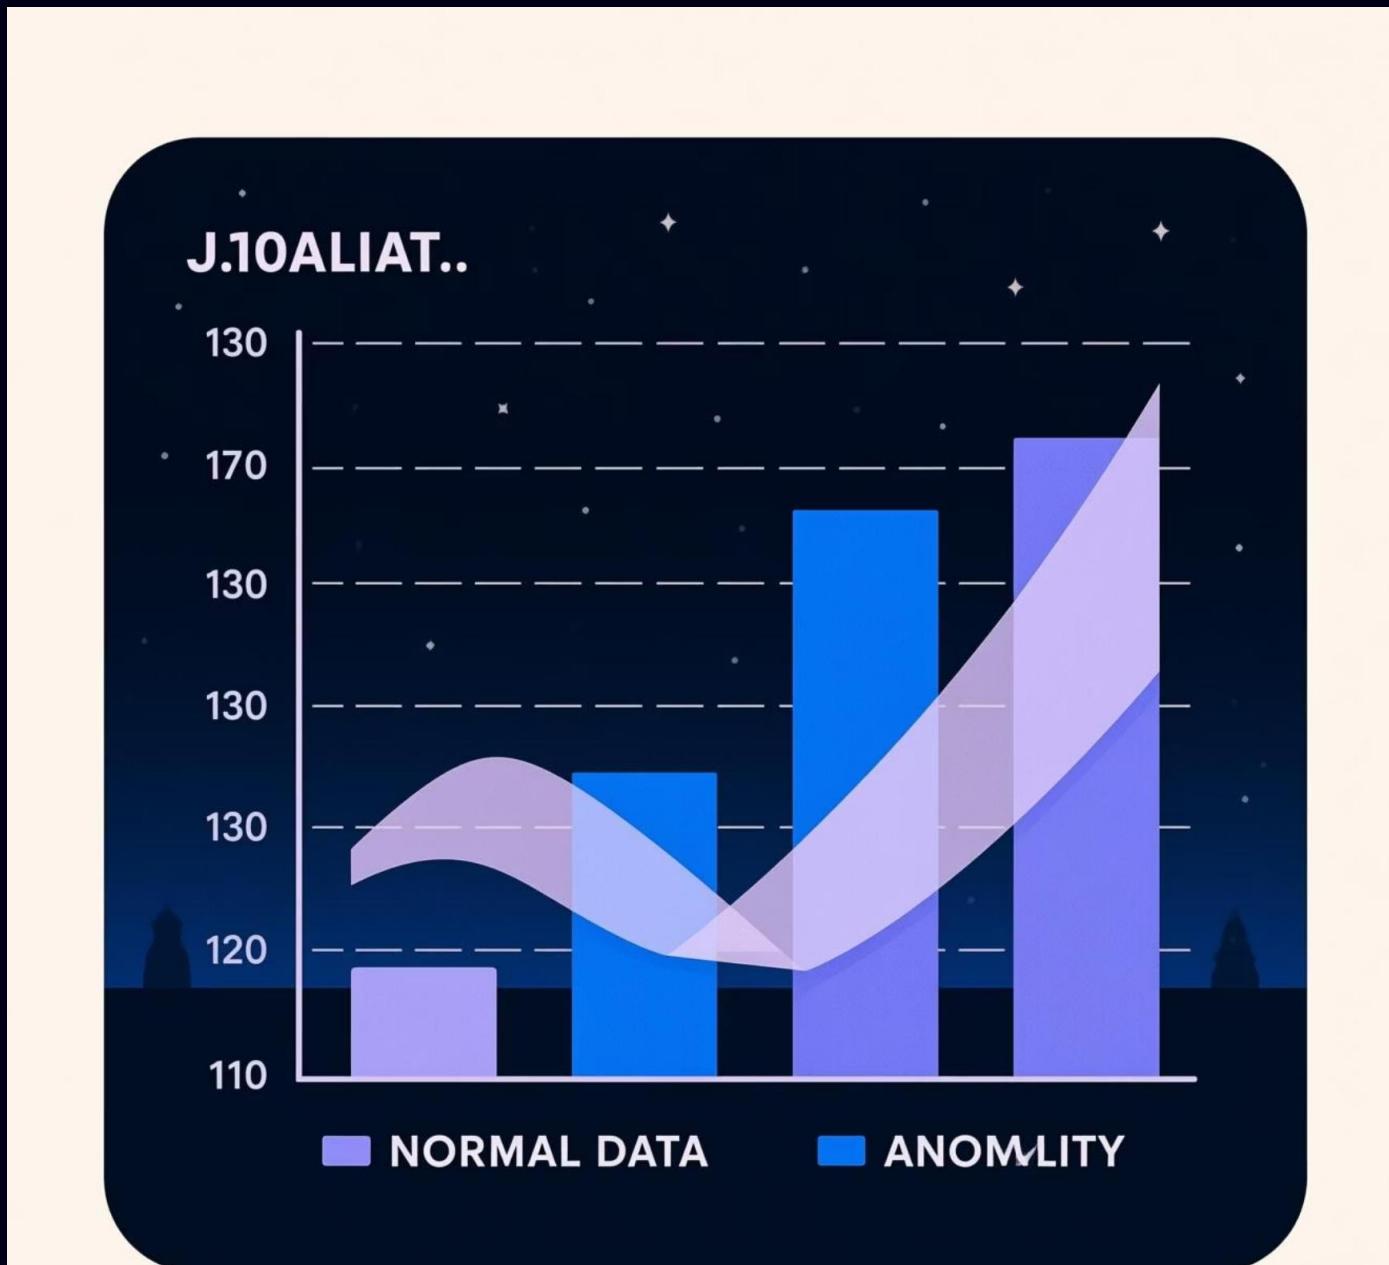
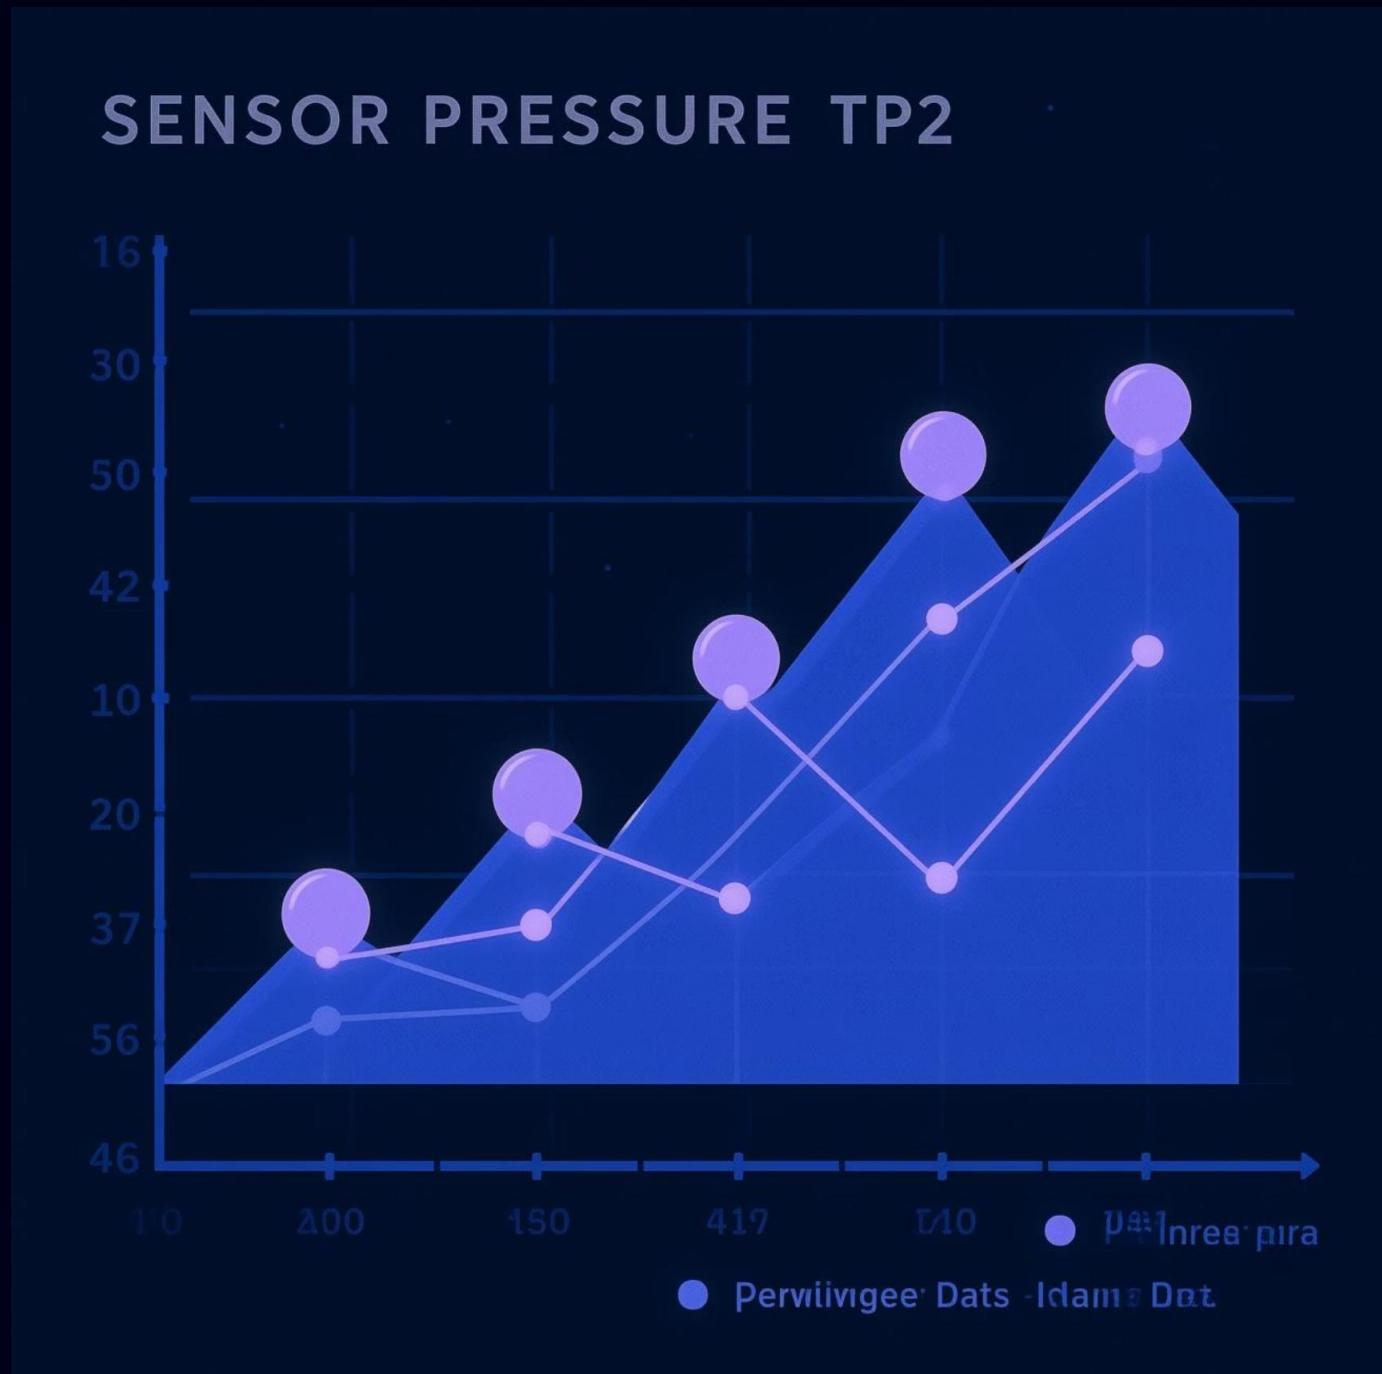
06

Pelatihan, Optimasi & Deployment

Optimizer Adam, binary cross-entropy, class weighting, early stopping, Keras Tuner. Model terbaik diekspor ke TensorFlow Lite.

Eksplorasi dan Pra-pemrosesan Data

Data sensor multivariat dan tidak seimbang, dengan data normal jauh lebih banyak dari anomali, menunjukkan kasus imbalanced classification.



Normalisasi dan Segmentasi Data

Normalisasi Min-Max Scaling mempertahankan pola temporal data, sementara proses sliding window menghasilkan format data yang sesuai untuk CNN-LSTM.

Perbandingan Data Sensor Sebelum dan Sesudah Normalisasi

Normalisasi menyamakan skala nilai ke rentang 0–1 tanpa mengubah pola temporal, membuat pelatihan model CNN-LSTM lebih stabil dan efektif.



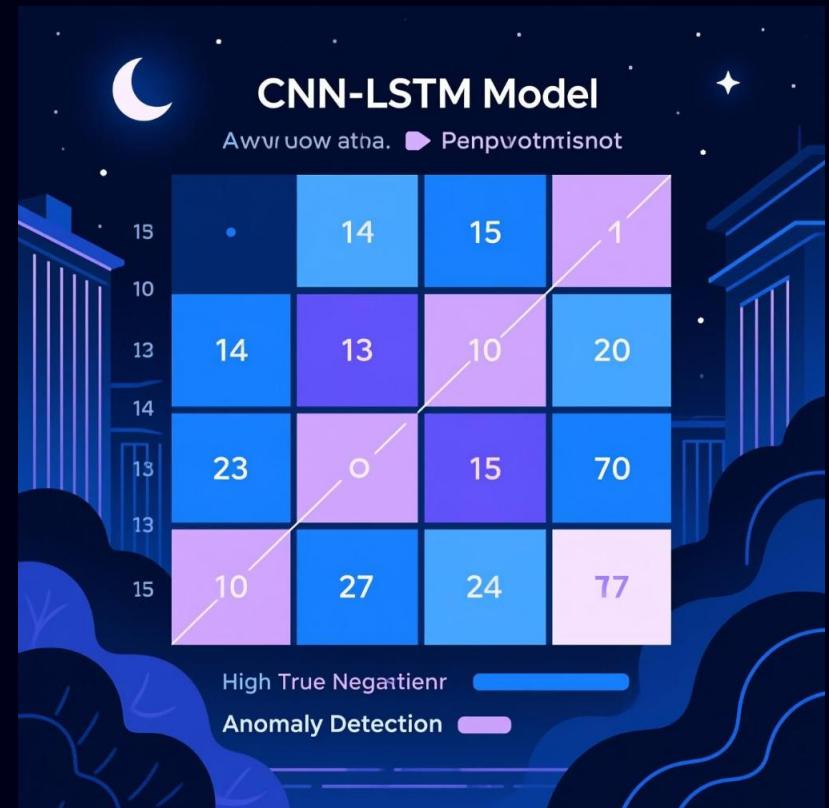
Evaluasi Model CNN-LSTM

Model CNN-LSTM menunjukkan performa sangat baik dengan akurasi tinggi dan kemampuan deteksi anomali yang seimbang.



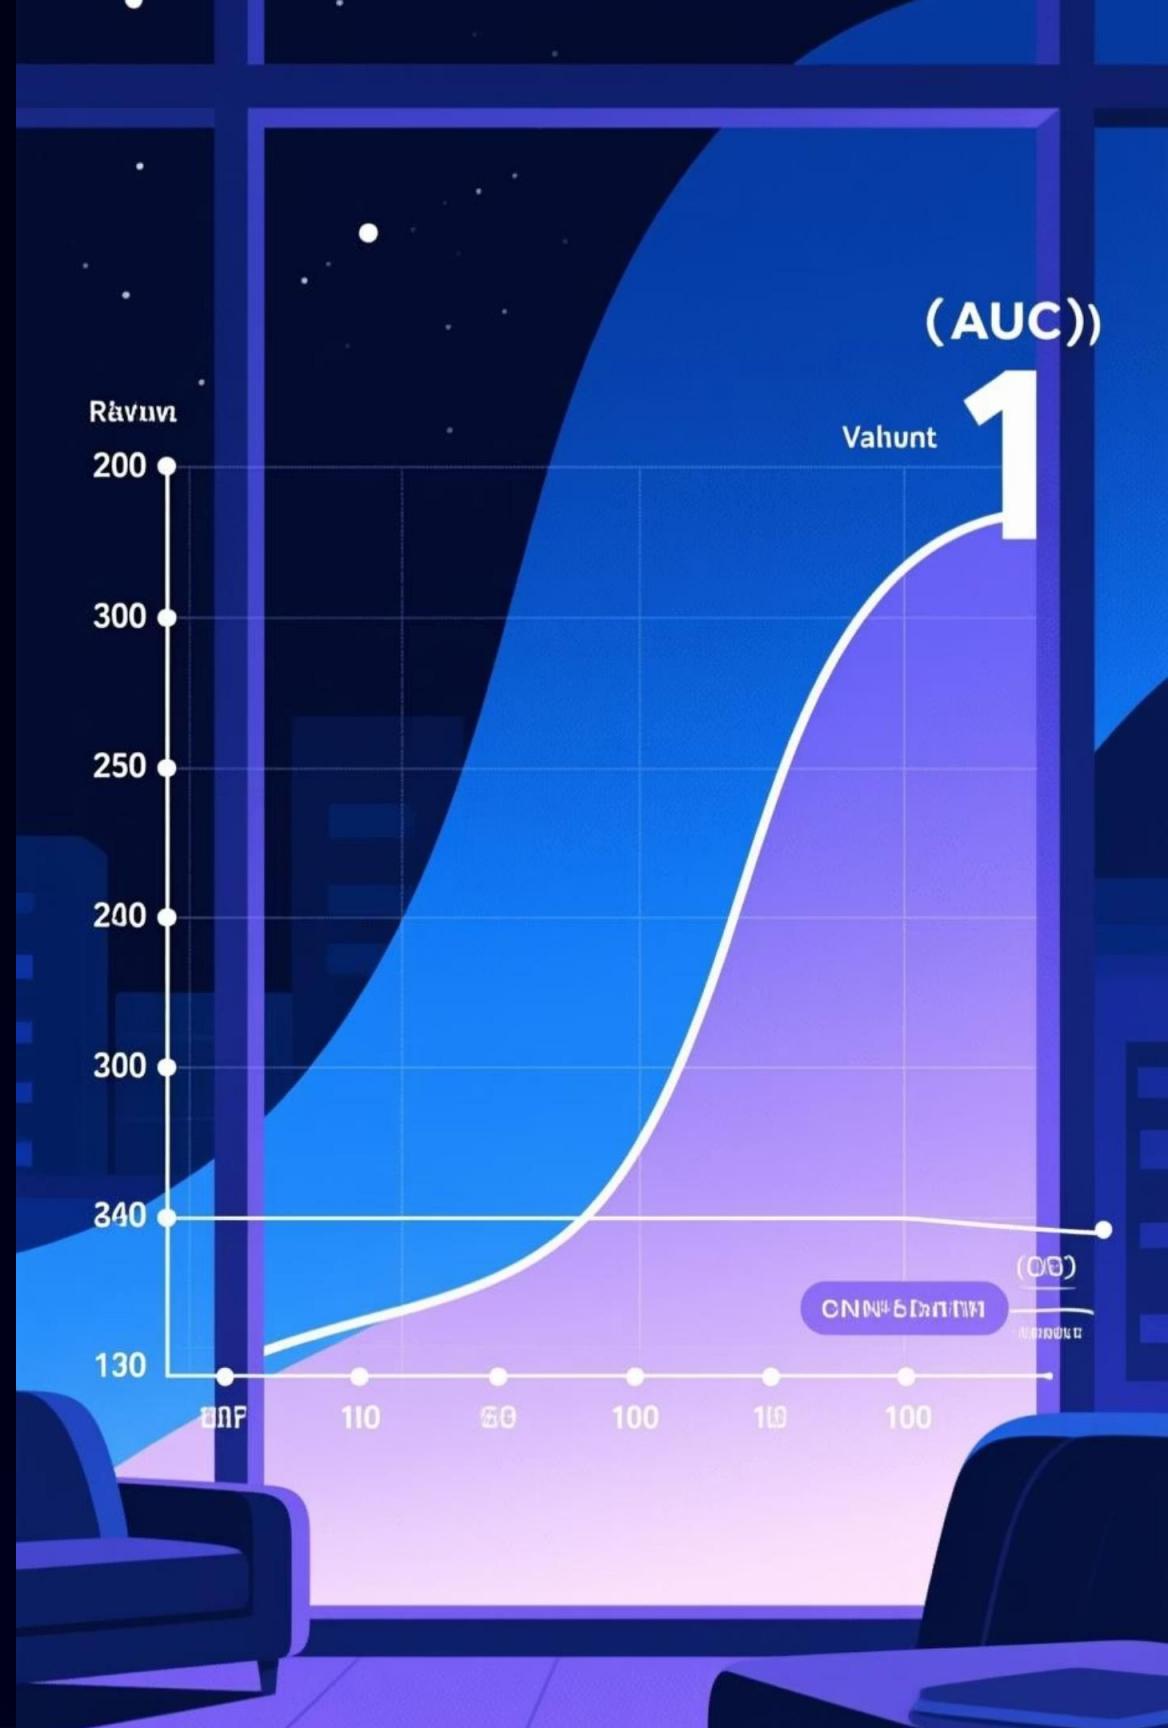
Kurva Pembelajaran

Penurunan loss yang konsisten menunjukkan model belajar dengan baik tanpa overfitting signifikan berkat early stopping.



Confusion Matrix

Mayoritas data (normal dan anomali) berhasil diklasifikasikan dengan benar, menunjukkan kemampuan deteksi anomali yang baik.



Kurva ROC Model CNN-LSTM

Nilai AUC mendekati 1 menunjukkan kemampuan pemisahan kelas yang sangat baik antara data normal dan anomali.



Kesimpulan & Rekomendasi

Model hybrid CNN–LSTM unggul dalam deteksi anomali pada data sensor IoT industri, terutama untuk data time series yang kompleks dan tidak seimbang.

Performa Superior

CNN–LSTM lebih unggul dari Random Forest dan SVM, terutama dalam recall dan F1-score.

Deployment Efisien

Konversi ke TensorFlow Lite memungkinkan implementasi pada perangkat edge IoT secara efisien.

Riset Lanjutan

Pengembangan metode pelabelan adaptif dan pengujian model pada data real-time.